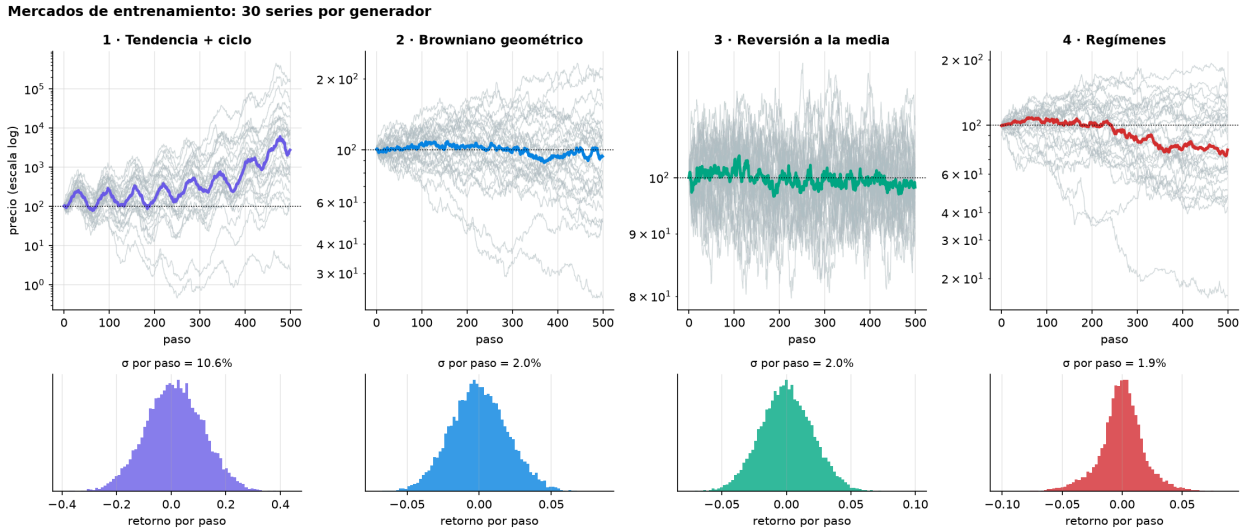
MÁSTER MIAX · APRENDIZAJE POR REFUERZO · TALLER 2

Agentes de Deep RL para trading de un activo

DQN y A3C en cuatro mercados sintéticos y en el S&P 500

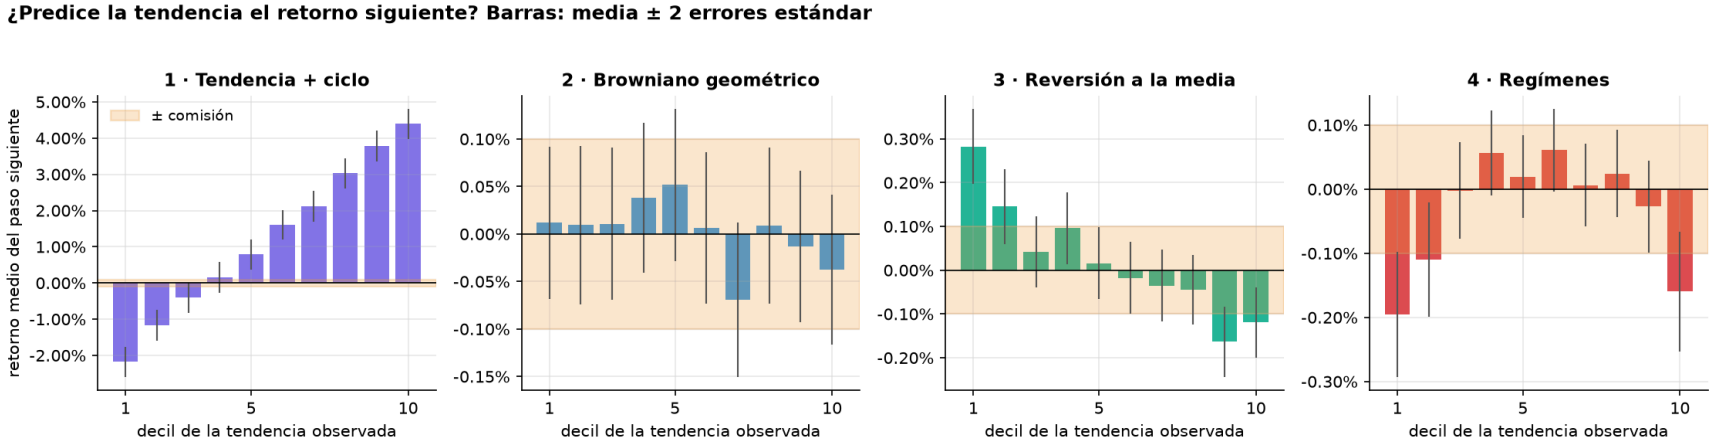


Óscar Romero Quincoces · Fernando Dapena Tauste · Daniel García López

Noviembre 2026 · Código y resultados: github.com/Romequinco/deep-rl-trading-agents

Solo hay señal en dos mercados, y una regla de un umbral ya la aprovecha

Retorno del paso siguiente por decil de tendencia: a favor en el 1, en contra en el 3; en el 2 y el 4 no cubre la comisión.



ENTORNO

Estado (tendencia, posición) · vender / mantener / comprar · comisión 0,1 %

→

RED

[tendencia/σ, posición] → 64 ReLU · entrada y recompensa normalizadas con train

→

ALGORITMOS

DQN (memoria y red objetivo) y A3C (3 procesos asíncronos)

→

PROTOCOLO

Serie nueva por episodio · 100 de validación · test en 200, una sola vez · 5 semillas · margen de ruido

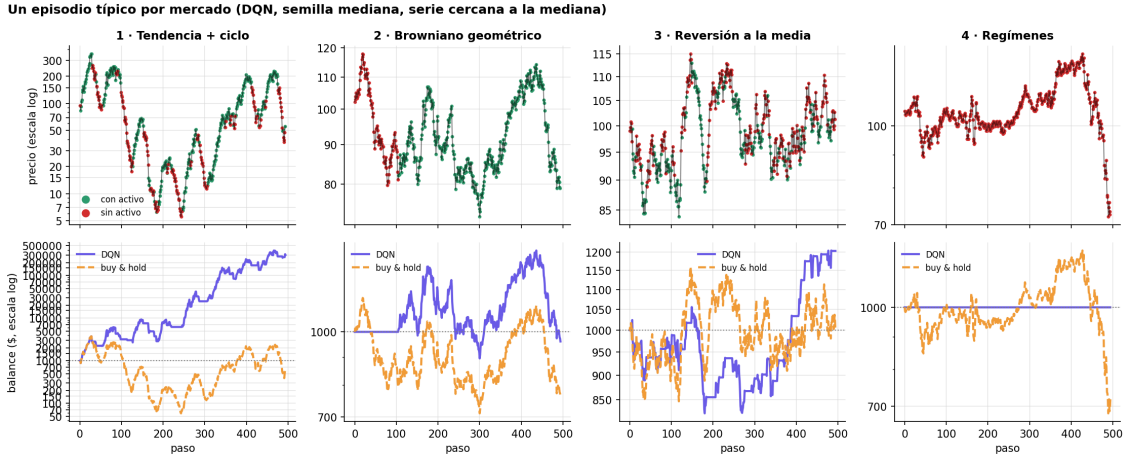
DQN aprende la estrategia esperada donde hay señal, sin llegar a la regla

1 · Tendencia + ciclo
x299,8
regla x630,4 · buy & hold x33,6

2 · Browniano
−3,9 %
no operar 0 % · buy & hold −3,5 %

3 · Reversión
+20,5 %
regla +29,2 % · buy & hold −0,3 %

4 · Regímenes
0 %
no operar 0 % · buy & hold −12,5 %



- **1:** sigue la tendencia, pero opera de más (53 operaciones).
- **3:** compra tras caídas y vende tras subidas.
- **2:** entra y se queda, como buy & hold.
- **4:** no opera: lo correcto.

$\alpha = 10^{-3}$ · $\gamma = 0{,}9$ · ε ×0,995 por episodio · 500 episodios. Ningún cambio supera el margen de ruido.

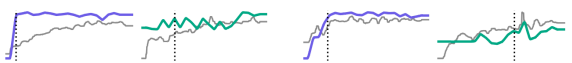
Un episodio típico de test (semilla mediana y serie con el retorno mediano de las 200): posición (arriba) y balance frente a buy & hold (abajo).

A3C empata con DQN y entrena 3,4 veces más rápido, pero converge peor

	1 Tendencia + ciclo	2 Browniano	3 Reversión	4 Regímenes
Aleatorio	x4.3	-19.4%	-17.2%	-22.0%
Buy & hold	x33.6	-3.5%	-0.3%	-12.5%
No operar	+0.0%	**+0.0%**	+0.0%	**+0.0%**
Regla tendencia	**x630.4**	-4.4%	-22.3%	-10.5%
Regla reversión	-50.1%	-4.8%	**+29.2%**	-10.6%
Q-Learning (T1)	x502.3	**+0.0%**	+27.0%	**+0.0%**
SARSA (T1)	x471.6	**+0.0%**	+27.0%	**+0.0%**
DQN	**x299.8**	**-3.9%**	**+20.5%**	**+0.0%**
A3C	**x374.9**	**-4.5%**	**+13.8%**	**+0.0%**

Mediana del retorno en test (200 series; DQN y A3C, mediana de 5 semillas). Recuadro = mejor del mercado.

A3C no usa ε: explora porque su política es estocástica, así que se ajusta la **entropía β**. Solo cambian α = 0,003 en el 1 y β = 0 en el 3.

Mercado 1 · 3	DQN	A3C
Test	x299,8 · **+20,5 %**	**x374,9** · +13,8 %
Convergen	**5/5 · 5/5**	4/5 · 3/5
Episodios	**25 · 125**	84 · 312
Curva		
Entreno total	33,0 s	**9,9 s**

Empate en rendimiento. A3C es más rápido por episodio; DQN converge antes y en todas las semillas: hasta converger tardan lo mismo.

Lo que decide es la información del estado, no el algoritmo

	1 Tendencia + ciclo	2 Browniano	3 Reversión	4 Regímenes
+20 retornos	**+0.40 5/5**	-0.07 0/5	**+0.09 4/5**	+0.04 3/5
+MA30 y volatilidad	-0.46 1/5	-0.03 1/5	**+0.25 5/5**	**+0.13 5/5**
Double DQN	-0.06 1/5	+0.00 2/5	**+0.03 3/5**	+0.00 2/5
Recompensa log	+0.22 4/5	+0.01 3/5	+0.00 3/5	+0.05 3/5
Placebo (sin tendencia)	-2.52 0/5	+0.05 4/5	-0.16 0/5	+0.00 2/5
Mezcla 4 mercados	-0.20 1/5	+0.00 2/5	-0.16 1/5	-0.09 0/5
A2C (vs A3C)	+0.09 3/5	-0.05 1/5	+0.00 2/5	+0.00 1/5

Ventaja log frente al DQN base en 400 series nuevas (mismas series y semillas) y semillas que mejoran; recuadro = supera el margen. Posterior al test: no cambia el resultado oficial.

x348 → x548

tendencia, añadiendo los 20 últimos retornos (5/5 semillas)

+16,8 → +47,9 %

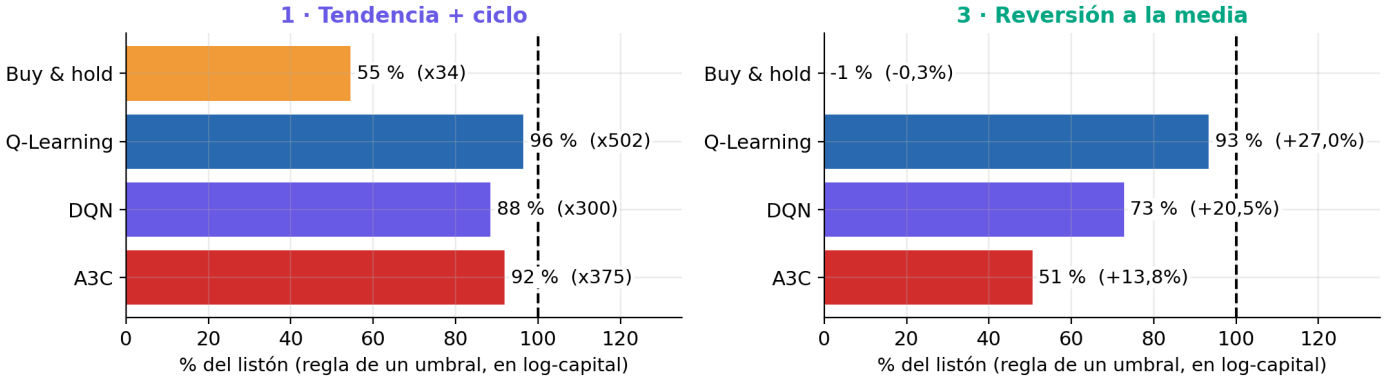
reversión, con media móvil de 30 y volatilidad (5/5)

+12,1 %

S&P 500 2024–25 entrenando con datos reales, frente a +43,8 % de buy & hold

Double DQN solo mejora en reversión; dueling, quitar la red objetivo o recortar la recompensa, nada. Sin la tendencia (placebo) solo compra y mantiene.

Aprenden lo esperado; el límite está en el estado, no en la red



MENSAJES CLAVE

- DQN y A3C **aprenden la estrategia esperada** en 3 de 4 mercados y baten a buy & hold donde hay señal.
- **Ninguno llega al listón** de la regla de un umbral, y Q-Learning queda por encima.
- **DQN ≈ A3C**: A3C más rápido, DQN más estable entre semillas.

LIMITACIONES Y TRABAJO FUTURO

- Con 2 variables una tabla basta: **enriquecer el estado** mejora más que cambiar de algoritmo.
- 5 semillas y márgenes descriptivos; recompensa en retornos simples.
- Mercados sintéticos y un S&P 500 de una sola trayectoria.

Preguntas

Anexos

Detalle de los resultados que la exposición resume.

A	Ajuste de hiperparámetros de DQN y A3C, y por qué normalizar la entrada
B	Políticas aprendidas: acción según la tendencia, semilla a semilla
C	Curvas de aprendizaje: con exploración frente a la política greedy
D	Un episodio de test de DQN y de A3C
E	Extras completos: las variantes de un solo cambio frente al DQN base
F	S&P 500 real: entrenamiento 2017–2021 y test 2024–2025

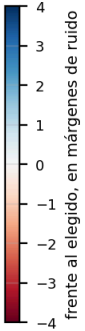
Solo γ y la normalización importan más que el ruido entre semillas

DQN

	1	2	3	4
α 1e-4	x585.7	+0.3%	+19.9%	+0.0%
α 3e-4	x405.4	+0.0%	+23.0%	-15.9%
α 1e-3	x505.5	-1.6%	+31.4%	+0.0%
γ 0	x561.6	+0.0%	+32.8%	-4.7%
γ 0.5	x488.3	+2.7%	+31.4%	-6.7%
γ 0.9	x505.5	-1.6%	+31.4%	+0.0%
γ 0.99	x212.2	+0.1%	+19.6%	-6.4%
ε×0.98	x583.6	-7.8%	+26.4%	+0.0%
ε×0.99	x542.4	-0.4%	+24.0%	+0.0%
ε×0.995	x505.5	-1.6%	+31.4%	+0.0%
ep. 300	x381.5	+1.0%	+4.6%	-10.6%
ep. 500	x505.5	-1.6%	+31.4%	+0.0%
ep. 1000	x515.7	-2.6%	+20.6%	-3.2%

A3C

	1	2	3	4
α 1e-4	x169.1	+0.0%	+10.1%	+0.0%
α 3e-4	x487.4	+0.0%	+21.1%	+0.0%
α 1e-3	x538.3	+1.8%	+21.0%	+0.0%
α 3e-3	x728.1	+0.0%	+21.6%	+0.0%
γ 0	x836.3	+0.0%	+5.3%	+0.0%
γ 0.5	x804.3	+0.0%	+4.7%	+0.0%
γ 0.9	x728.1	+1.8%	+21.0%	+0.0%
γ 0.99	x43.3	-5.7%	+15.1%	+0.0%
β=0	x68.1	+0.0%	+25.9%	+0.0%
β=0.001	x500.1	+0.0%	+20.2%	+0.0%
β=0.01	x728.1	+1.8%	+21.0%	+0.0%
β=0.05	x469.1	+0.0%	+22.3%	+0.0%
ep. 300	x530.2	+0.0%	+6.0%	+0.0%
ep. 500	x728.1	+1.8%	+25.9%	+0.0%
ep. 1000	x727.6	+0.0%	+24.6%	-19.1%



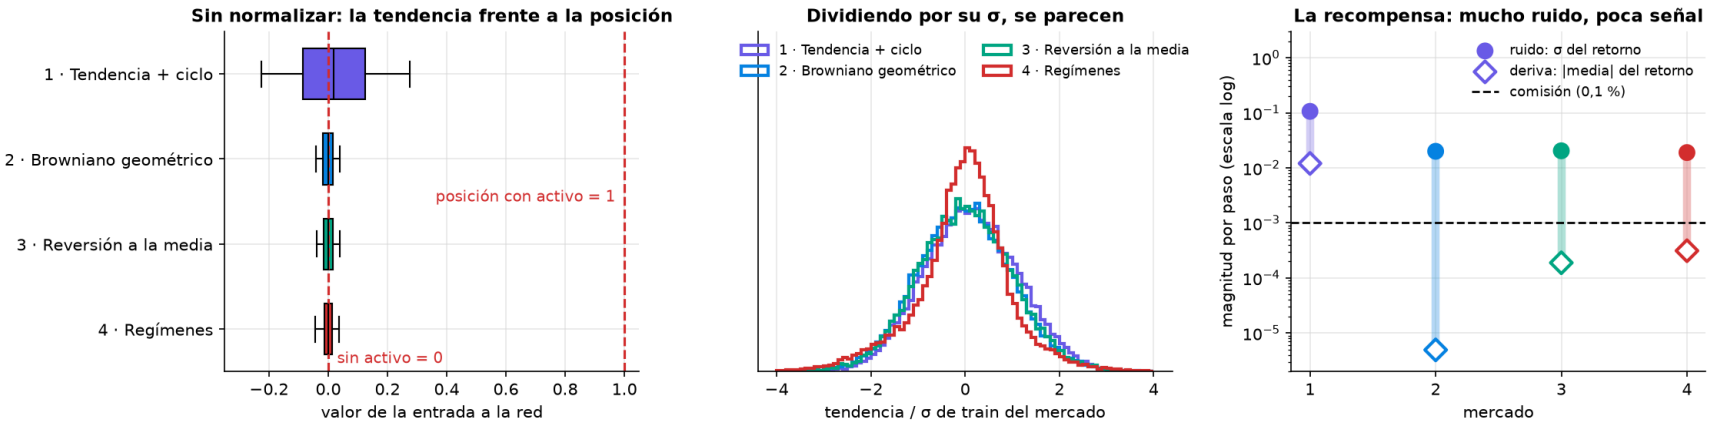
Validación, mediana de 3 semillas. Recuadro = valor elegido (A3C: por mercado).

- Un parámetro cada vez, en 100 series de validación con 3 semillas.
- Un valor solo se adopta si mejora más que ~2 errores estándar: 25 % del múltiplo en 1, 2 puntos en 3 y 10 en 2 y 4.
- **DQN:** ningún cambio lo supera; γ = 0,99 cae a x212.
- **A3C:** α = 0,003 en 1 (x538 → x728) y β = 0 en 3 (+21,0 → +25,9 %); γ = 0,99 hunde el 1 a x43.

Mediana en validación de cada valor probado; color = diferencia con el elegido en márgenes de ruido; recuadro = elegido.

Sin normalizar, la red apenas distingue la tendencia y deja de operar en reversión

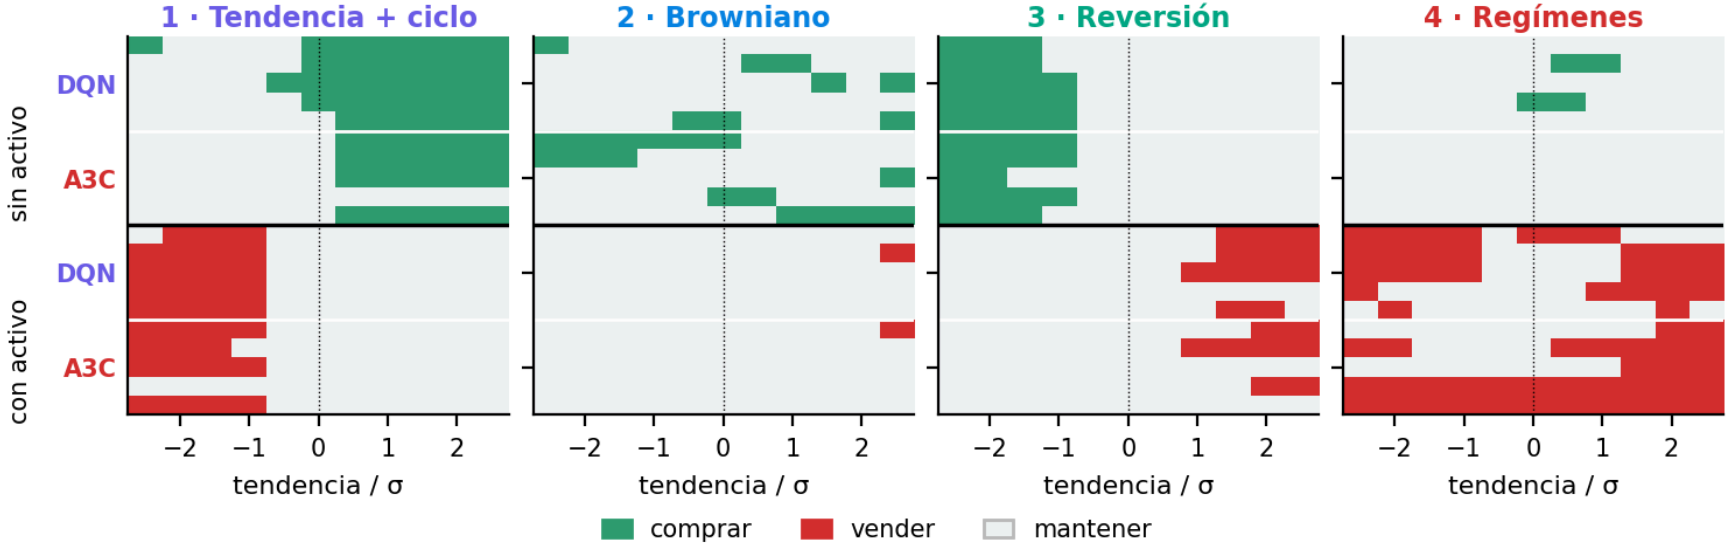
Escala de lo que ve y recibe la red (50 series de train)



- La tendencia tiene σ = 0,153 en el mercado 1 y 0,024 en el resto, frente a una posición de 0 o 1; la recompensa es del orden de 10^{-3}.
- Ambas se dividen por su σ calculada **solo con series de train**; las métricas se miden con el balance real.

Reversión (validación)	DQN	A3C
Sin normalizar	+2,3 %	0 % (no opera)
Observación y recompensa	**+31,4 %**	**+21,0 %**

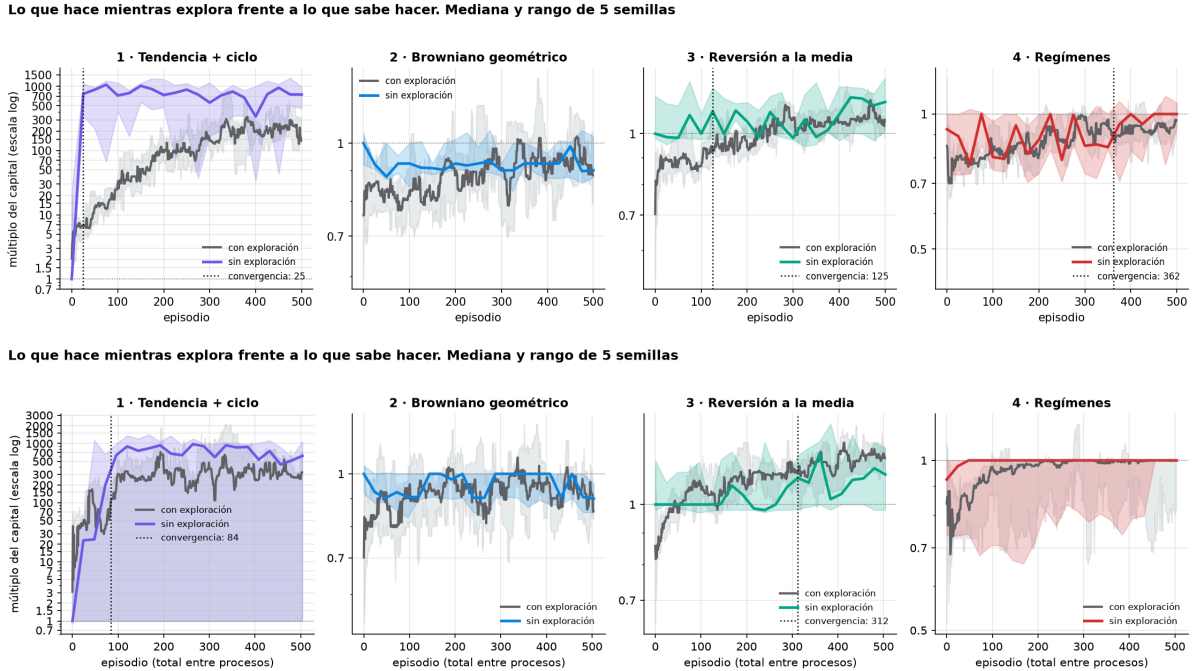
DQN y A3C llegan a casi la misma tabla de decisiones



- **1 · Tendencia:** compran con tendencia positiva y venden al girar a negativa.
- **2 · Browniano:** sin patrón claro; una vez dentro casi nunca venden.
- **3 · Reversión:** compran tras caídas fuertes y venden tras subidas fuertes.
- **4 · Regímenes:** A3C no compra nunca; DQN compra poco y vende ante movimientos grandes.

Acción greedy de cada una de las 5 semillas en 11 niveles de tendencia entre −2,5σ y +2,5σ, sin activo (comprar) y con activo (vender).

DQN alcanza su nivel en 25 episodios; A3C tarda más y varía más entre semillas



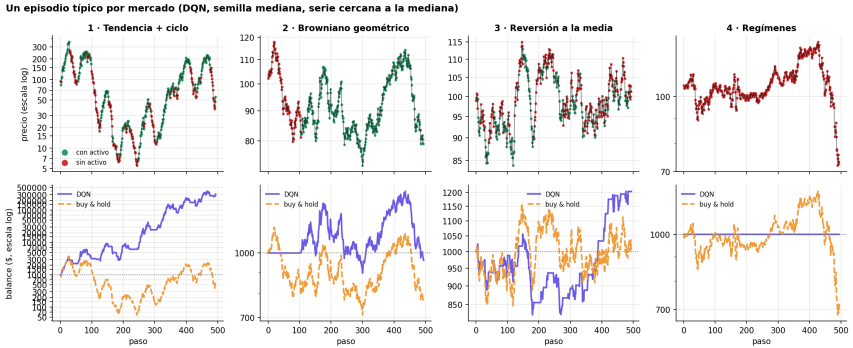
Arriba DQN, abajo A3C. Gris: retorno con exploración; color: política greedy en 20 series de validación. Mediana y rango de 5 semillas.

- Con ε, DQN opera al azar casi todo el entrenamiento: la curva gris queda muy por debajo.
- A3C explora muestreando su política, por eso las curvas están más cerca.
- En el 4 ambas greedy quedan en 0: aprenden pronto a no operar.

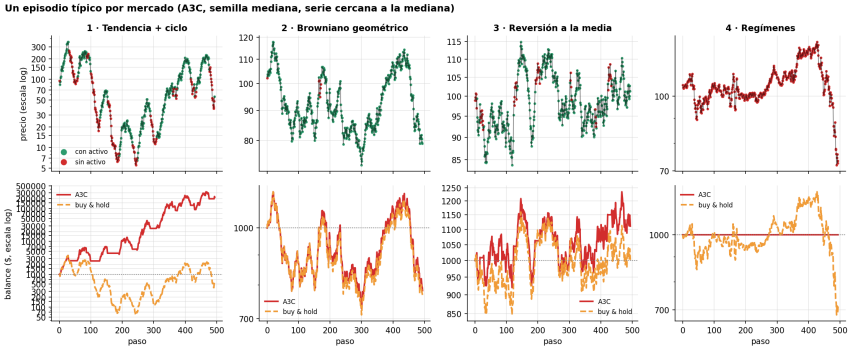
Convergencia: primer punto que recorre el 90 % del camino hasta el nivel final.

Las dos redes operan igual donde hay señal y se apartan donde no la hay

DQN



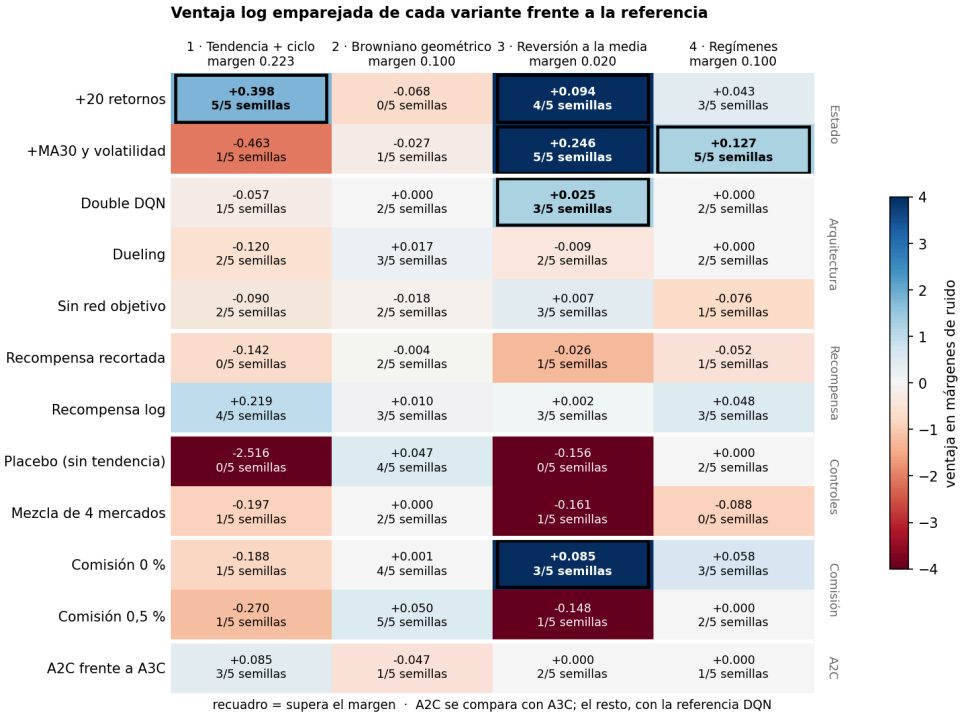
A3C



Semilla mediana y, en cada mercado, la serie de test con el retorno mediano de DQN (la misma para A3C). Arriba, precio con la posición (verde dentro, rojo fuera); abajo, balance frente a buy & hold.

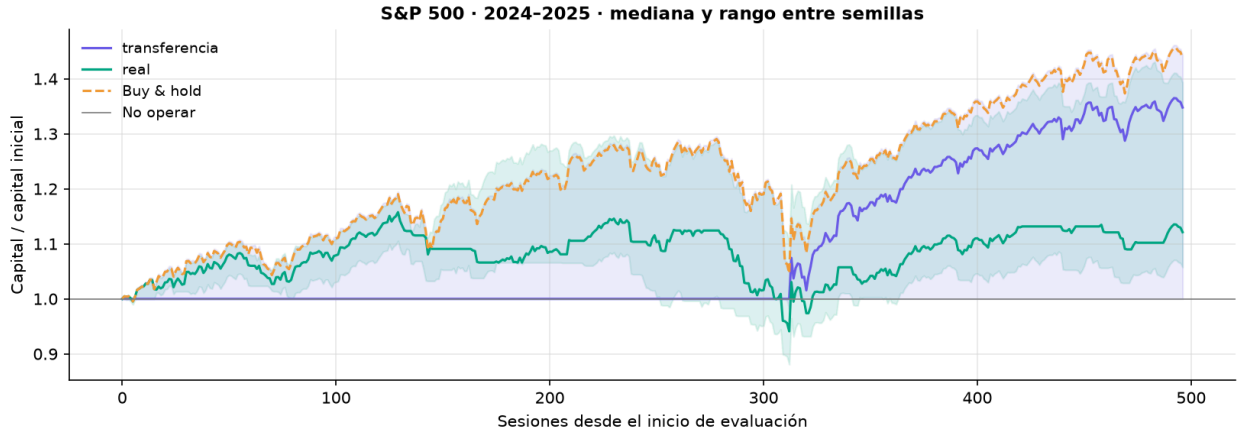
- **1 · Tendencia:** los dos entran con la subida y salen al girar el ciclo.
- **3 · Reversión:** compran en las caídas y venden en los rebotes.
- **2 · Browniano:** se quedan dentro y siguen a buy & hold.
- **4 · Regímenes:** ninguno opera; el balance se queda en el capital inicial mientras buy & hold pierde.

Solo cambiar el estado supera el margen de forma consistente



- Cada variante cambia **una sola cosa** respecto al DQN base; 5 semillas y 400 series nuevas por mercado.
- Ventaja = mediana de $\log(1 + r_{\text{variante}}) - \log(1 + r_{\text{base}})$ serie a serie; recuadro si supera el margen.
- **Estado:** +20 retornos y MA30 + volatilidad son lo único consistente.
- **Arquitectura y recompensa:** Double DQN solo en reversión; el resto, nada.
- **Comisión 0 %** «mejora» porque cambia la tarea, no el algoritmo.
- Placebo y mezcla de mercados empeoran, como se esperaba.

En el S&P 500 ninguna variante bate a buy & hold



Test 2024–2025	Retorno	Caída máx.	Operaciones
Buy & hold	**+43,8 %**	18,9 %	1
DQN (train browniano)	+34,8 %	5,5 %	1
DQN (train S&P 500)	+12,1 %	16,7 %	75
Aleatorio	+2,1 %	16,1 %	163

- Train 2017–2021, validación 2022–2023, test 2024–2025; normalización solo con train.
- Una única trayectoria: 5 semillas son 5 entrenamientos, no 5 históricos.
- Retrospectivo y sin dividendos, spread ni deslizamiento.